

Sprawozdanie z projektu: Rozpoznawanie mowy

Wiktor Murawski

27 maja 2026

Spis treści

1	Cel i zakres projektu	2
1.1	Zadanie klasyfikacji	2
1.2	Implementacji	2
2	Zbiór danych	2
2.1	Struktura nagrań	2
2.2	Obserwacje jakościowe	3
3	Metoda	3
3.1	Wstępne przetwarzanie sygnału	3
3.2	Ekstrakcja cech MFCC	4
3.3	Dynamic Time Warping (DTW)	4
3.4	Klasyfikacja 1-NN	5
4	Ewaluacja	5
4.1	Protokoły ewaluacyjne	5
4.2	Metryki	6
5	Wyniki	6
5.1	Tryb repetition (speaker-dependent)	6
5.2	Ewaluacja leave-one-speaker-out (LOSO)	7
5.3	Porównanie trybów ewaluacji	8
6	Wnioski	8

1 Cel i zakres projektu

Celem projektu jest zbudowanie systemu automatycznego rozpoznawania izolowanych liczb języka polskiego (od *zero* do *dziesięć*) wypowiedzianych przez różnych mówców. Problem ten należy do klasy rozpoznawania słów – jednego z trzech podstawowych zadań analizy mowy, obok weryfikacji tożsamości i identyfikacji mówcy.

1.1 Zadanie klasyfikacji

System otrzymuje na wejściu nagranie WAV zawierające jedną wypowiedzianą liczbę i zwraca jej etykietę tekstową. Zdefiniowano 11 klas:

zero, jeden, dwa, trzy, cztery, pięć, sześć, siedem, osiem, dziewięć,
dziesięć

1.2 Implementacji

System zaimplementowano w języku Python 3.14. Zgodnie z wymaganiami, implementacja kluczowych algorytmów (ekstrakcja MFCC, algorytm DTW) została wykonana samodzielnie, bez korzystania z bibliotek dostarczających gotowe implementacje. Biblioteki `numpy` i `scipy` zostały użyte wyłącznie do operacji macierzowych i FFT. Do wczytania plików dźwiękowych wykorzystano bibliotekę `soundfile`.

2 Zbiór danych

2.1 Struktura nagrań

Zbiór danych zawiera nagrania zebrane od 17 mówców¹. Każdy mówca wypowiedział każdą z 11 liczb dwukrotnie, co daje łącznie $17 \times 11 \times 2 = 374$ nagrania.

Tabela 1: Parametry zbioru danych

Parametr	Wartość
Liczba mówców	17
Liczba klas (liczb)	11
Nagrań na klasę na mówcę	2
Łączna liczba nagrań	374
Częstotliwość próbkowania	22 050 Hz
Format	WAV, mono

¹Oryginalne numery mówców obejmowały zakres 1–28, jednak część numerów była nieobecna w zbiorze; ostatecznie użyto nagrań od mówców o identyfikatorach: 01–10, 13, 14, 22–25, 28.

2.2 Obserwacje jakościowe

Podczas analizy zbioru zaobserwowano niejednorodność jakości nagrań. W szczególności nagrania mówcy 01 wykazywały wyraźne przestery (*clipping*) – zniekształcenie polegające na obcinaniu sygnału do wartości maksymalnej, gdy amplituda przekracza zakres przetwornika. Nagrania mówcy 22 często były w dużej części przedwcześnie ucięte. Znalazło to odzwierciedlenie w wynikach klasyfikacji.

3 Metoda

System składa się z czterech etapów: wstępnego przetwarzania sygnału, ekstrakcji cech MFCC, obliczania dystansu DTW oraz klasyfikacji metodą 1 najbliższego sąsiada (1-NN).

3.1 Wstępne przetwarzanie sygnału

1. **Wczytanie i normalizacja amplitudy.** Sygnał wczytywany jest jako liczby zmienneoprzecinkowe w zakresie $[-1, 1]$. Nagrania stereofoniczne są uśredniane do mono. Następnie sygnał normalizowany jest względem wartości szczytowej:

$$x_{\text{norm}}[n] = \frac{x[n]}{\max_n |x[n]|} \quad (1)$$

2. **Preemfaza.** Widmo sygnału mowy opada ze wzrostem częstotliwości z nachyleniem ok. -6 dB/oktawę . Filtr górnoprzepustowy pierwszego rzędu wyrównuje to widmo, poprawiając numeryczną stabilność FFT:

$$y[n] = x[n] - \alpha \cdot x[n-1], \quad \alpha = 0,97 \quad (2)$$

3. **Detekcja aktywności głosowej (VAD).** Cisza na początku i końcu nagrania jest usuwana na podstawie energii krótkoterminowej. Dla każdej ramki o długości 20 ms obliczana jest wartość RMS; ramki poniżej progu 0,02 uznawane są za ciszę. Zachowany jest margines 50 ms po obu stronach aktywności.
4. **Ramkowanie i okienkowanie.** Sygnał dzielony jest na nakładające się ramki o długości $L = 25 \text{ ms}$ z krokiem $S = 10 \text{ ms}$ (60% nakładania). Każda ramka mnożona jest przez okno Hamminga redukujące wyciek widmowy:

$$w[n] = 0,54 - 0,46 \cos\left(\frac{2\pi n}{N-1}\right), \quad n = 0, \dots, N-1 \quad (3)$$

3.2 Ekstrakcja cech MFCC

Mel-Frequency Cepstral Coefficients (MFCC) to standardowa reprezentacja cech sygnału mowy, zaproponowana przez Davis i Mermelsteina w 1980 roku [1]. Ekstrakcja przebiega w następujących krokach dla każdej ramki:

Krok 1: Szybka transformata Fouriera (FFT)

Dla każdej ramki obliczany jest periodogram (widmo mocy):

$$P[k] = \frac{1}{N} |X[k]|^2, \quad X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N} \quad (4)$$

Wystarczy wyznaczyć $N/2 + 1$ unikalnych binów ze względu na symetrię widma sygnału rzeczywistego.

Krok 2: Filtrbank Mela

Skala Mela odzwierciedla nieliniową percepcję wysokości dźwięku przez ludzkie ucho – ludzki słuch jest bardziej czuły na różnice w niskich niż w wysokich częstotliwościach. Konwersja:

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right) \quad (5)$$

Zdefiniowano $M = 26$ trójkątnych filtrów rozmieszczonych równomiernie w skali Mela między $f_{\min} = 0$ Hz a $f_{\max} = 11\,025$ Hz. Energia w m -tym filtrze:

$$E[m] = \sum_k P[k] \cdot H_m[k] \quad (6)$$

Krok 3: Logarytm i DCT

Logarytm kompresuje dynamikę energii (imitując percepcję głośności zgodnie z prawem Webera-Fechnera). Dyskretna transformata kosinusowa (DCT-II) dekorreluje współczynniki i redukuje ich redundancję:

$$c[i] = \sum_{m=0}^{M-1} \ln(E[m]) \cos \left(\frac{\pi i}{M} \left(m + \frac{1}{2} \right) \right), \quad i = 1, \dots, 13 \quad (7)$$

Pominięto współczynnik $c[0]$ (energia DC); zachowano $K = 13$ współczynników.

3.3 Dynamic Time Warping (DTW)

Dwa nagrania tej samej liczby mogą różnić się długością nawet o 30–50% ze względu na tempo mówienia. Proste porównanie ramka-do-ramki byłoby w takim przypadku zawodne

– jeśli jedno nagranie ma 60 ramek, a drugie 80, nie ma jednoznacznego sposobu żeby je zestawić.

DTW rozwiązuje ten problem przez elastyczne dopasowanie osi czasu. Zamiast porównywać ramki o tych samych indeksach, algorytm szuka optymalnego przyporządkowania ramek jednego nagrania do ramek drugiego – pozwalając na lokalne rozciągnięcia i skrócenia. Formalnie minimalizuje sumaryczną odległość wzdłuż najlepszej możliwej ścieżki przez macierz odległości lokalnych [2].

Wynik DTW to pojedyncza liczba – im mniejsza, tym bardziej podobne dwa nagrania. W systemie klasyfikacji nowe nagranie porównywane jest ze wszystkimi wzorcami w bazie i przypisywane do klasy o najmniejszym dystansie DTW.

Aby zapobiec patologicznym dopasowaniom i przyspieszyć obliczenia, zastosowano ograniczenie okna Sakoe-Chiba [2]: ścieżka dopasowania nie może odbiegać od przekątnej macierzy o więcej niż 20 ramek (≈ 200 ms). Oznacza to, że ramka nr i z jednego nagrania może być dopasowana tylko do ramek $i - 20, \dots, i + 20$ z drugiego nagrania – co odpowiada dopuszczalnemu lokalnemu przyspieszeniu lub zwolnieniu tempa mówienia o około 200 ms.

3.4 Klasyfikacja 1-NN

System stosuje metodę **1 najbliższego sąsiada** opartą na dystansie DTW – podejście klasyczne, niewymagające uczenia żadnych parametrów.

W fazie treningu system po prostu zapamiętuje macierze MFCC wszystkich nagrań treningowych wraz z ich etykietami. Nie następuje żadna optymalizacja – baza wzorców to dosłownie zbiór przykładów przechowywanych w pamięci.

W fazie predykcji, dla każdego nagrania testowego, system oblicza dystans DTW do każdego wzorca w bazie i zwraca etykietę wzorca o najmniejszym obliczonym dystansie.

4 Ewaluacja

4.1 Protokoły ewaluacyjne

Zastosowano dwa protokoły podziału danych na zbiór treningowy i testowy:

Repetition (speaker-dependent). Pierwsze nagranie każdej liczby (*_1.wav) stanowi zbiór treningowy, drugie (*_2.wav) – testowy. Wszyscy mówcy są obecni w obu zbiorach, co sprawia, że system “zna” głos każdej osoby. Jest to łatwiejszy scenariusz, przydatny do weryfikacji poprawności implementacji.

Speaker-independent. Nagrania wybranych mówców stanowią zbiór testowy; nagrania pozostałych osób – treningowy. System musi sklasyfikować liczby wymawiane przez mówców, których nigdy wcześniej nie słyszał. Scenariusz bardziej realistyczny.

4.2 Metryki

Zastosowano standardowe metryki klasyfikacji wieloklasowej:

$$\text{Accuracy} = \frac{\text{TP}_{\text{total}}}{N} \quad (8)$$

$$\text{Precision}_c = \frac{\text{TP}_c}{\text{TP}_c + \text{FP}_c} \quad (9)$$

$$\text{Recall}_c = \frac{\text{TP}_c}{\text{TP}_c + \text{FN}_c} \quad (10)$$

$$F_1^{(c)} = 2 \cdot \frac{\text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad (11)$$

gdzie:

- TP_c (true positive) – liczba nagrań klasy c poprawnie rozpoznanych jako c ,
- FP_c (false positive) – liczba nagrań innej klasy błędnie rozpoznanych jako c ,
- FN_c (false negative) – liczba nagrań klasy c błędnie przypisanych do innej klasy,
- TP_{total} – suma TP po wszystkich klasach (łączna liczba poprawnych klasyfikacji),
- N – łączna liczba nagrań testowych.

5 Wyniki

5.1 Tryb repetition (speaker-dependent)

W trybie repetition pierwsze nagranie każdej cyfry (*_1.wav) stanowiło zbiór treningowy, drugie (*_2.wav) – testowy. Wszyscy mówcy byli obecni w obu zbiorach. System osiągnął dokładność **97,3%** (182/187 nagrań), klasyfikując każde nagranie w średnim czasie 157 ms.

Tabela 2: Błędne klasyfikacje w trybie repetition (5 z 187 nagrań testowych)

Plik	Prawdziwe	Predykcja
22/1_2.wav	jeden	dziewięć
07/4_2.wav	cztery	dwa
09/5_2.wav	pięć	dwa
14/5_2.wav	pięć	dziewięć
14/10_2.wav	dziesięć	sześć

Tabela 3: Metryki per klasa – tryb repetition

Klasa	Precision	Recall	F1
zero	1,000	1,000	1,000
jeden	1,000	0,941	0,970
dwa	0,895	1,000	0,944
trzy	1,000	1,000	1,000
cztery	1,000	0,941	0,970
pięć	1,000	0,882	0,938
sześć	0,944	1,000	0,971
siedem	1,000	1,000	1,000
osiem	1,000	1,000	1,000
dziewięć	0,895	1,000	0,944
dziesięć	1,000	0,941	0,970
Średnia	0,976	0,973	0,973

Najniższy wynik $F1 = 0,938$ uzyskała klasa *pięć* – jedyna cyfra z dwoma błędami, oba u różnych mówców (09 i 14). Klasy *zero*, *trzy*, *siedem* i *osiem* uzyskały $F1 = 1,000$, co oznacza bezbłędną klasyfikację we wszystkich 17 przypadkach testowych.

5.2 Ewaluacja leave-one-speaker-out (LOSO)

Przeprowadzono 17 rund ewaluacji – w każdej rundzie jeden mówca pełnił rolę testową, pozostałych 16 tworzyło zbiór treningowy. Średnia dokładność wyniosła **95,2%** (356/374 nagrań).

Najgorszy wynik uzyskał mówca 22 (81,8%), którego nagrania były w znacznej części przedwcześnie ucięte – brakuje końcówki wymawianej liczby. DTW porównuje wówczas niepełną sekwencję ramek z kompletnymi wzorcami treningowymi, co zaburza obliczane dystanse. Słabą dokładność uzyskano także w przypadku mówcy 01, którego nagrania cechowały się silnym przesterem. Pokazuje to, że jakość nagrań ma krytyczny wpływ na wyniki systemu.

Siedmiu mówców (02, 03, 04, 06, 13, 23, 25) uzyskało 100% dokładność, co potwierdza że dla nagrań dobrej jakości i standardowej wymowy system MFCC+DTW jest skuteczny.

Tabela 4: Wyniki ewaluacji LOSO per mówca

Mówca	Dokładność	Poprawne/Wszystkie	Uwagi
01	86,4%	19/22	przestery (clipping)
02	100,0%	22/22	
03	100,0%	22/22	
04	100,0%	22/22	
05	90,9%	20/22	
06	100,0%	22/22	
07	90,9%	20/22	
08	95,5%	21/22	
09	95,5%	21/22	
10	95,5%	21/22	
13	100,0%	22/22	
14	90,9%	20/22	
22	81,8%	18/22	nagrania ucięte przedwcześnie
23	100,0%	22/22	
24	95,5%	21/22	
25	100,0%	22/22	
28	95,5%	21/22	
Średnia	95,2%	356/374	

5.3 Porównanie trybów ewaluacji

Tabela 5: Porównanie wyników obu protokołów ewaluacyjnych

Protokół	Dokładność	Poprawne/Wszystkie
Repetition (speaker-dependent)	97,3%	182/187
LOSO (speaker-independent)	95,2%	356/374

6 Wnioski

1. System MFCC + DTW z klasyfikatorem 1-NN osiągnął dokładność **97,3%** w scenariuszu speaker-dependent i **95,2%** w scenariuszu speaker-independent na zbiorze 11 polskich liczb.
2. Niewielka degradacja (2,1 pp) między trybami potwierdza, że MFCC skutecznie abstrahuje od cech indywidualnych głosu mówcy, zachowując informację fonetyczną.
3. Jakość nagrań okazała się czynnikiem krytycznym. Mówca z przesterami (01) oraz mówca z uciętymi końcówkami wymawianych liczb (22) odpowiadali za dużą część błędów. W praktycznych systemach ASR preprocessing jakości sygnału (detekcja i korekcja clippingu, normalizacja dynamiczna) może być ważniejszy niż wybór algorytmu klasyfikacji.

4. Potencjalne kierunki ulepszeń:

- **Większy zbiór danych** – zebranie nagrań od większej ilości mówców mogłoby pozwolić na stworzenie lepszych wzorców i uzyskanie bardziej uniwersalnego modelu;
- **Augmentacja danych** – sztuczne zniekształcenia (szum, zmiana tempa, symulacja clippingu) w zbiorze treningowym zwiększyłyby odporność modelu;
- **Klasyfikator ML** – zamiana 1-NN/DTW na SVM lub sieć neuronową (np. LSTM) przy zagregowanych cechach MFCC może poprawić wyniki szczególnie dla trudnych klas.

Literatura

- [1] Davis, S., Mermelstein, P., *Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences*, IEEE Transactions on Acoustics, Speech, and Signal Processing, vol. 28, no. 4, 1980.
- [2] Sakoe, H., Chiba, S., *Dynamic Programming Algorithm Optimization for Spoken Word Recognition*, IEEE Transactions on Acoustics, Speech, and Signal Processing, vol. 26, no. 1, 1978.